

ГУАП

КАФЕДРА № 41

ОТЧЕТ  
ЗАЩИЩЕН С ОЦЕНКОЙ  
ПРЕПОДАВАТЕЛЬ

канд. техн. наук, доцент

должность, уч. степень, звание

Г.В. Титова

подпись, дата

инициалы, фамилия

ОТЧЕТ О ЛАБОРАТОРНОЙ РАБОТЕ № 2

СТАТИСТИЧЕСКАЯ ПРОВЕРКА КРИТЕРИЕВ

по курсу:

СТАТИСТИЧЕСКАЯ ОБРАБОТКА ИНФОРМАЦИИ

РАБОТУ ВЫПОЛНИЛ

СТУДЕНТ гр. № 4318

подпись, дата

А.Д. Борисоглебский

инициалы, фамилия

Санкт-Петербург 2025

## **СОДЕРЖАНИЕ**

ВВЕДЕНИЕ .....	3
1 Описание данных .....	4
2 Наглядное представление .....	6
3 Критерий Шапиро-Уилка .....	9
4 Критерий корреляции Спирмена .....	11
5 Критерий корреляции Кендалла .....	13
6 Критерий Манна-Уитни .....	15
7 Медианный критерий .....	17
7.1 Критерий Краскела-Уоллиса .....	20
8 Вывод .....	22

## **ВВЕДЕНИЕ**

**Цель работы:** провести статистическую проверку критериев.

Данные взяты с сайта статистики Испании, из раздела демографии. Данные содержат информацию о рождении, естественному приросту населения и случаях внутриутробной смерти в абсолютный величинах (кол-во случаев).

Ссылка: [https://www.ine.es/jaxiT3/Datos.htm?t=6567#\\_tabs-tabla](https://www.ine.es/jaxiT3/Datos.htm?t=6567#_tabs-tabla)

Также для проведения более полного исследования были взяты данные о случаях домашнего насилия в регионах, также в абсолютных величинах.

Ссылка: <https://www.ine.es/dynInfo/Infografia/Territoriales/capitulo.html#!tabla>

Данные по рождаемости относятся к 2023 году. Данные по насилию к 2024-му. Однако разница не будет ощутима, так как глобальные изменения в поведении населения не возникают за такие короткие промежутки времени.

## 1 Описание данных

Данные взяты по 19-ти регионам Испании.

Из основного источника взяты признаки: рождаемость, естественный прирост, случаи смерти плода. Из дополнительных данных взята статистика по жертвам насилия, домашнего и в общем.

Итоговые датафреймы представлены на рисунках 1–2.

	Autonomous Communities and Cities	Nacimiento	Natural growth	Late foetal deaths
0	01 Andalucia	61397.0	-13299.0	153.0
1	02 Aragon	8669.0	-5188.0	27.0
2	03 Asturias, Principado de	4545.0	-8467.0	29.0
3	04 Balears, Illes	8738.0	99.0	37.0
4	05 Canarias	11998.0	-5832.0	37.0
5	06 Cantabria	2976.0	-3056.0	2.0
6	07 Castilla y Leon	12496.0	-15606.0	29.0
7	08 Castilla - La Mancha	14075.0	-5372.0	30.0
8	09 Catalunya	54174.0	-13488.0	131.0
9	10 Comunitat Valenciana	35378.0	-11305.0	121.0
10	11 Extremadura	6810.0	-4551.0	26.0
11	12 Galicia	14004.0	-18778.0	22.0
12	13 Madrid, Comunidad de	50299.0	1653.0	94.0
13	14 Murcia, Region de	12860.0	660.0	41.0
14	15 Navarra, Comunidad Foral de	4496.0	-1351.0	19.0
15	16 País Vasco	13462.0	-8866.0	54.0
16	17 Rioja, La	1999.0	-1237.0	9.0
17	18 Ceuta	683.0	123.0	3.0
18	19 Melilla	771.0	271.0	6.0
19	Foreign	826.0	-1878.0	6.0
20	Total	320656.0	-115468.0	876.0

Рисунок 1 — Датафрейм с данными о рождаемости

	Víctimas de violencia de género	Víctimas de violencia doméstica
0	8.020	1.851
1	994	237
2	704	189
3	1.307	415
4	2.441	500
5	681	132
6	1.879	538
7	1.889	394
8	2.768	940
9	4.858	1.106
10	938	255
11	1.350	384
12	3.432	1.025
13	1.588	342
14	426	123
15	766	249
16	358	117
17	115	32
18	170	31

Рисунок 2 — Датафрейм с данными о жертвах насилия

## 2 Наглядное представление

Распределение данных о рождении детей и естественном приросте по регионам представлено на рисунке 3.

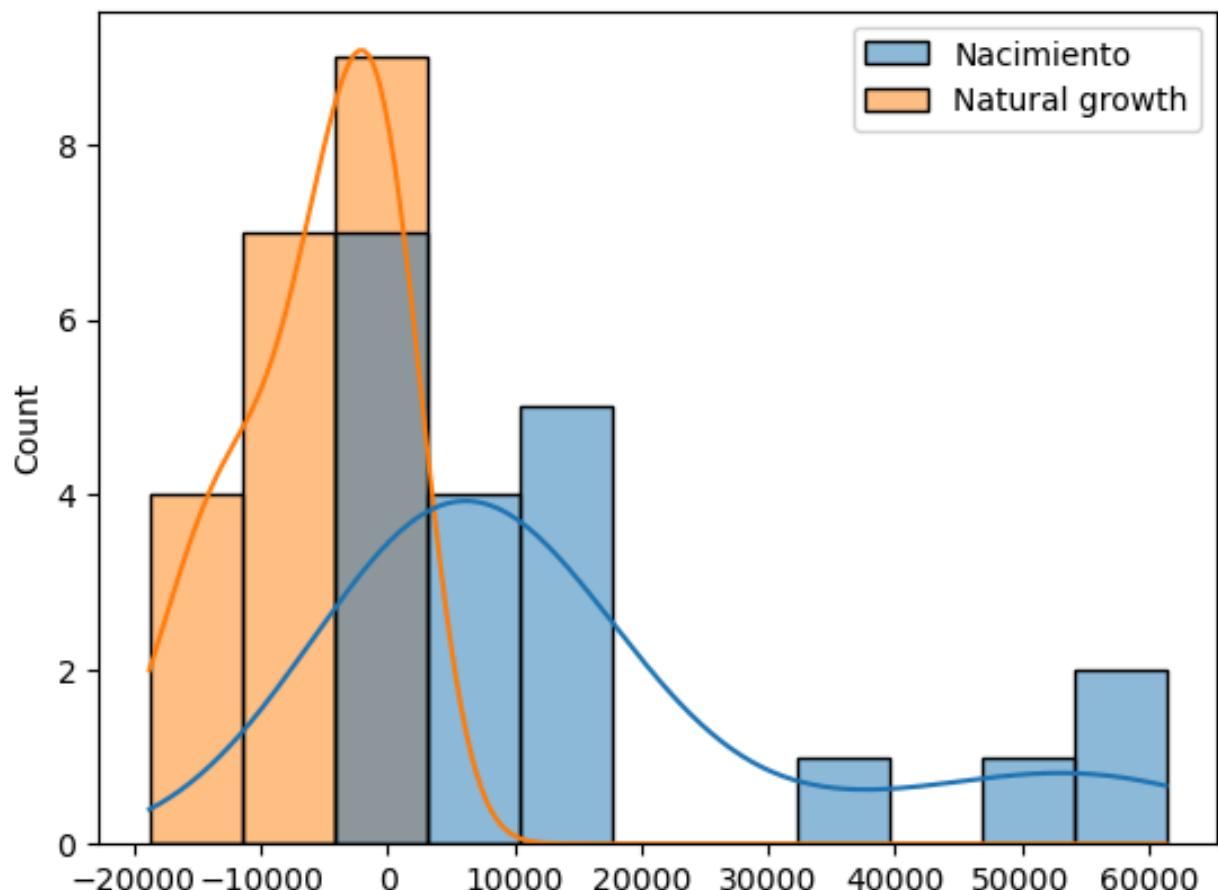


Рисунок 3 — График распределения признаков

Распределение данных о случаях смерти по регионам представлено на рисунке 4.

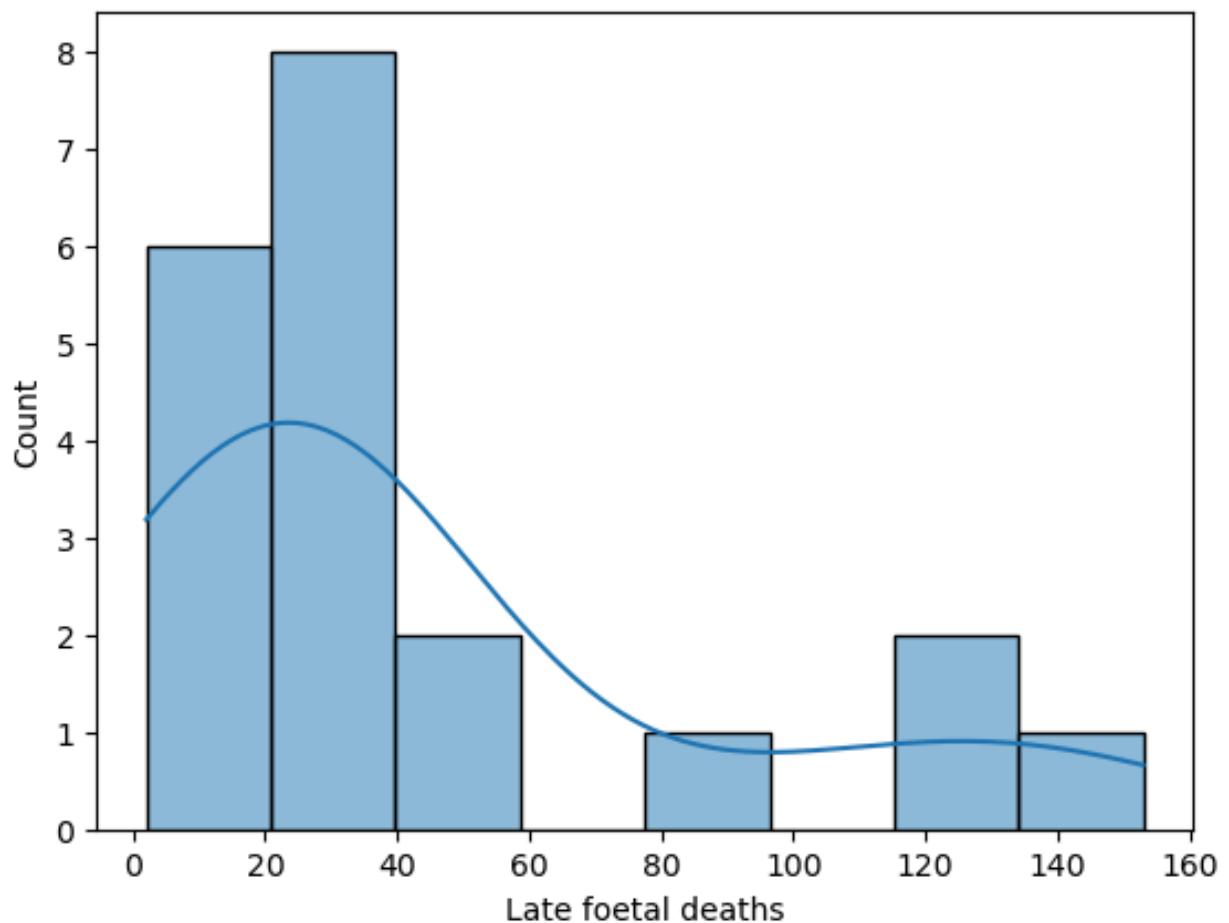


Рисунок 4 — График распределения признаков

Распределение данных о случаях домашнего и общего насилия по регионам представлено на рисунке 5.

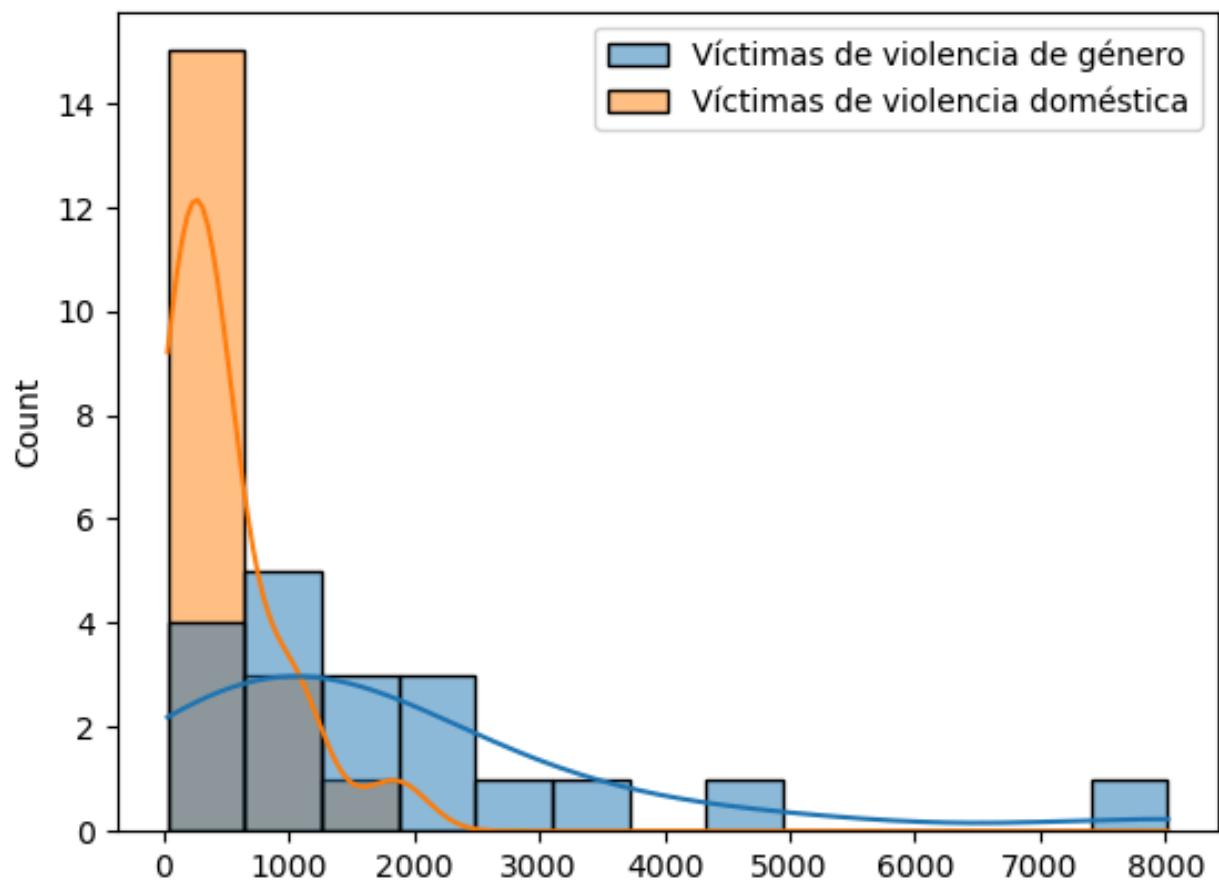


Рисунок 5 — График распределения признаков по насилию

### **3 Критерий Шапиро-Уилка**

#### **Для чего используется:**

Критерий проверяет, является ли распределение данных нормальным. Если доказана нормальность, то можно использовать параметрические методы (корреляция Пирсона), а если нет — нужно использовать непараметрические (Спирмен, Манн-Уитни). По результатам этого теста решается, какие критерии применять в дальнейшем исследовании.

#### **Условия применения:**

- $3 \leq n \leq 50$  (при большем количестве снижается точность)
- Проверка нормальности

**Для признаков:** Рождения, естественный прирост, случаи смерти.

#### **Нулевая гипотеза:**

$$H_0 = \{f(x) = N(a, \sigma^2)\}$$

Данные распределены нормально

#### **Альтернативная гипотеза:**

$$H_1 = \{f(x) \neq N(a, \sigma^2)\}$$

Данные не распределены нормально

#### **Формула:**

$$W = \frac{\left(\sum_{i=1}^n a_i x_{(i)}\right)^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad (1)$$

где:

- $x_{(i)}$  — упорядоченные значения выборки
- $a_i$  — коэффициенты, рассчитываемые на основе ожидаемых значений порядковых статистик нормального распределения
- $\bar{x}$  — среднее значение выборки
- $n$  — объём выборки

#### **Команда в Python:**

```
from scipy.stats import shapiro  
stat, p = shapiro(x)
```

Тест Шапиро-Уилка показал, что данные не распределены нормально (табл. 1).

Таблица 1 — Результаты критерия Шапиро-Уилка

Признак	W	p-value	Сравнение	Вывод
Рождения	0.7446	0.0002	$p \leq 0.05$	Отвергаем $H_0$ , значит данные НЕ нормальны
Естественный прирост	0.9234	0.1306	$p \geq 0.05$	Не может отвергнуть $H_0$ , однако выборка из 18 значений и статистика 0.92 свидетельствует о недостаточной нормальности распределения
Сметри плода	0.7983	0.0011	$p \leq 0.05$	Отвергаем $H_0$ , значит данные НЕ нормальны
Случай домашнего насилия	0.8029	0.0013	$p \leq 0.05$	Отвергаем $H_0$ , значит данные НЕ нормальны

В результате все данные не подчиняются нормальному закону распределения (в полной мере). Для дальнейшего исследования используем непараметрические критерии.

## **4 Критерий корреляции Спирмена**

### **Для чего используется:**

Критерий показывает, есть ли связь между двумя признаками. Если один признак растёт, растёт ли вместе с ним другой (положительная связь), или наоборот — один растёт, а другой падает (отрицательная связь).

Используем для проверки связи между домашним насилием и случаями смерти детей.

### **Условия применения:**

- $n \geq 5$
- Непараметрический
- Не требует нормальности

### **Для признаков:**

Домашнее насилие и случаи смерти детей. Попытаемся определить, есть ли зависимость.

### **Нулевая гипотеза:**

$$H_0 = \{\rho_s = 0\}$$

Корреляция отсутствует

### **Альтернативная гипотеза:**

$$H_1 = \{\rho_s > 0\} \text{ — положительная корреляция}$$

$$H_2 = \{\rho_s < 0\} \text{ — отрицательная корреляция}$$

$$H_3 = \{\rho_s \neq 0\} \text{ — корреляция существует (выбрано через } \text{alternative}=\text{"two-sided"})$$

Корреляция существует

### **Формула:**

Коэффициент корреляции Спирмена:

$$\rho_s = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)} \quad (2)$$

где:

- $d_i$  — разность между рангами соответствующих значений X и Y
- $n$  — объём выборки

- $\rho_s \in [-1, 1]$  (от -1 до 1)

**Команда в Python:**

```
from scipy.stats import spearmanr  
corr, p = spearmanr(violencia_domestica, deaths)
```

**Паргументы по умолчанию:**

- axis=0 — вычисление корреляции по столбцам
- nan\_policy='propagate' — обработка пропущенных значений (NaN тоже учитывает)
- alternative='two-sided' — двусторонняя альтернатива ( $\rho \neq 0$ )

**Результат:**  $p\text{-value} \leq 0.05$

**Вывод:** Отвергаем  $H_0$ . Существует высокая корреляция ( $\rho = 0.8516$ ).

**Интерпретация:** Положительная корреляция. Данные изменяются вместе, однако нельзя утверждать о наличии причинно-следственной связи. Вероятнее всего есть общий показатель, влияющий на исследуемые значения (например, численность населения регионов).

## **5 Критерий корреляции Кендалла**

### **Для чего используется:**

Критерий Кендалла проверяет связь между двумя признаками. Основное отличие — Кендалл более устойчив к выбросам и лучше подходит для небольших выборок. Используется как дополнительная проверка корреляции. В работе применяется для анализа связи между

### **Условия применения:**

- $n \geq 5$
- Устойчив к выбросам
- Не требует нормальности

### **Для признаков:**

Домашнее насилие и случаи смерти детей. Берём те же данные, чтобы проверить ту же гипотезу другим способом.

### **Нулевая гипотеза:**

$$H_0 = \{\tau = 0\}$$

Корреляция отсутствует

### **Альтернативная гипотеза:**

$$H_1 = \{\tau \neq 0\}$$

Корреляция существует

### **Формула:**

Коэффициент корреляции Кендалла:

$$\tau = \frac{C - D}{\frac{n(n-1)}{2}} \quad (3)$$

где:

- $C$  — количество согласованных (конкордантных) пар
- $D$  — количество несогласованных (дискордантных) пар
- $n$  — объём выборки
- $\tau \in [-1, 1]$  (от  $-1$  до  $1$ )

### **Команда в Python:**

```
from scipy.stats import kendalltau  
corr, p = kendalltau(a, b)
```

### **Аргументы по умолчанию:**

- `method='auto'` — автоматический выбор метода вычисления (может быть `asymptotic` для больших выборок либо `exact` для точности и маленьких выборок)
- `variant='b'` — вариант статистики  $\tau$  Кендалла (`«b»` - для пар наблюдений, а `«c»` - для прямоугольных таблиц сопряженности)
- `alternative='two-sided'` — двусторонняя альтернатива
- `nan_policy='propagate'` — обработка пропущенных значений

**Результат:**  $p\text{-value} \leq 0.05$

**Вывод:** Отвергаем  $H_0$ . Корреляция существует ( $\tau = 0.6647$ )

**Интерпретация:** Положительная связь — данные измененияются согласованно. Двумя способами получен одинаковый вывод.

## **6 Критерий Манна-Уитни**

### **Для чего используется:**

Критерий сравнивает две группы и проверяет, различаются ли они статистически.

В работе используется для сравнения естественного прироста в регионах — проверяем, действительно ли две группы отличаются друг от друга.

### **Условия применения:**

- 2 независимые группы
- $n_1, n_2 \geq 3$
- Не требует нормальности

### **Для признаков:**

Естественный прирост (2 группы,  $n_1 = 9, n_2 = 10$ ).

Выборка разделена на две группы по медиане:

- Группа 1: регионы с рождаемостью  $< 8738$
- Группа 2: регионы с рождаемостью  $\geq 8738$

### **Нулевая гипотеза:**

$$H_0 = \{F_{X_1}(x) = F_{X_2}(x)\}$$

Распределения идентичны (две независимые выборки принадлежат однородным генеральным совокупностям)

### **Альтернативная гипотеза:**

$$H_1 = \{F_{X_1}(x) \neq F_{X_2}(x)\}$$

Распределения различаются

### **Формула:**

U-статистика Манна-Уитни:

$$U = n_1 n_2 + \frac{n_1(n_1 + 1)}{2} - R_1 \quad (4)$$

где:

- $n_1, n_2$  — объёмы первой и второй выборок
- $R_1$  — сумма рангов элементов первой выборки в общей упорядоченной выборке

- Вычисляется также  $U' = n_1 n_2 - U$ , используется  $\min(U, U')$

### Команда в Python:

```
from scipy.stats import mannwhitneyu  
stat, p = mannwhitneyu(low, high, alternative='two-sided')
```

### Аргументы по умолчанию:

- `use_continuity=True` — применение поправки на непрерывность (True рекомендуется для малых выборок)
  - `alternative='two-sided'` — двусторонняя альтернатива
  - `method='auto'` — автоматический выбор метода вычисления
  - `nan_policy='propagate'` — обработка пропущенных значений
  - `keepdims=False` — не сохранять размерность массива (False - скалярный результат, True - массив)

### Результат:

$U = 73.0, p = 0.0247$

$p\text{-value} \leq 0.05$  — отвергаем  $H_0$

**Вывод:** Регионы с высокой рождаемостью ( $\geq 8738$ ) имеют статистически значимо отличающийся естественный прирост по сравнению с регионами с низкой рождаемостью.

## **7 Медианный критерий**

### **Для чего используется:**

Критерий сравнивает медианы двух или более групп. Работает проще, чем Манн-Уитни — делит все данные на две категории (выше и ниже общей медианы) и сравнивает пропорции. Более устойчив к сильным выбросам. Используется как проверка различий между группами регионов по смертности.

### **Условия применения:**

- 2+ группы
- Устойчив к выбросам
- Не требует нормальности

### **Для признаков:**

Смертность (2 группы,  $n_1 = 9, n_2 = 10$ ).

Выборка разделена на две группы по медиане:

- Группа 1: регионы с рождаемостью  $< 8738$
- Группа 2: регионы с рождаемостью  $\geq 8738$

### **Нулевая гипотеза:**

$$H_0 = \{x_1 = x_2 = \dots = x_n\}$$

Медианы всех выборок равны (несколько независимых выборок принадлежат однородным генеральным совокупностям)

### **Альтернативная гипотеза:**

$$H_1 = \{\text{хотя бы одно равенство не выполняется}\}$$

Хотя бы одна медиана отличается от других

### **Формула:**

Медианный критерий использует статистику хи-квадрат:

$$\chi^2 = \sum_{i=1}^k \sum_{j=1}^2 \frac{(O_{ij} - E_{ij})^2}{E_{ij}} \quad (5)$$

где:

- $O_{ij}$  — наблюдаемые частоты (количество значений выше/ниже общей медианы в каждой группе)
- $E_{ij}$  — ожидаемые частоты при условии равенства медиан
- $k$  — количество групп

**Команда в Python:**

```
from scipy.stats import median_test
stat, p, med, contingency = median_test(low, high)
```

**Аргументы по умолчанию:**

- `ties='below'` — обработка значений, равных медиане (`below` - считать их ниже медианы)
- `correction=True` — применение поправки Йейтса (`True` - улучшает точность на малых выборках)
- `lambda_=1` — параметр для вычисления статистики (`1` - стандартная статистика Пирсона  $X^2$ )
- `nan_policy='propagate'` — обработка пропущенных значений

**Результат:**

$$\chi^2 = 6.4653$$

$$p\text{-value} = 0.0110$$

**Вывод:** Существует статистически значимая связь между уровнем рождаемости и уровнем смертности. Регионы с низкой и высокой рождаемостью по-разному распределяются относительно медианного уровня смертности.

**Интерпретация:**

Группа с низкой рождаемостью ( $< 8738$ ):

- 1 регион имеет смертность выше медианы;
- 8 регионов имеют смертность ниже медианы;
- 89% регионов с низкой рождаемостью имеют низкую смертность.

Группа с высокой рождаемостью ( $\geq 8738$ ):

- 8 регионов имеют смертность выше медианы;

- 2 региона имеют смертность ниже медианы;
- 80% регионов с высокой рождаемостью имеют высокую смертность.

## 7.1 Критерий Краскела-Уоллиса

### Для чего используется:

Критерий сравнивает три или больше групп одновременно. Проверяет, различаются ли группы по уровню признака. В работе используется для проверки того, отличаются ли регионы с разным уровнем домашнего насилия (низкий, ниже среднего, выше среднего, высокий) по рождаемости.

### Условия применения:

- 3+ группы
- Не требует нормальности

### Для признаков:

Рождаемость (4 группы). Разделение уровня насилия по квантилям.

### Нулевая гипотеза:

$$H_0 = \{F_{X_1}(x) = F_{X_2}(x) = \dots = F_{X_k}(x)\}$$

Все выборки принадлежат однородным генеральным совокупностям (медианы равны)

### Альтернативная гипотеза:

$$H_1 = \{\text{хотя бы одно равенство не выполняется}\}$$

Хотя бы одна медиана отличается

### Формула:

H-статистика Краскела-Уоллиса:

$$H = \frac{12}{n(n+1)} \sum_{i=1}^k \frac{R_i^2}{n_i} - 3(n+1) \quad (6)$$

где:

- $k$  — количество групп
- $n$  — общий объём выборки ( $n = \sum_{i=1}^k n_i$ )
- $n_i$  — объём  $i$ -й группы
- $R_i$  — сумма рангов  $i$ -й группы в общей упорядоченной выборке

### Команда в Python:

```
from scipy.stats import kruskal  
stat, p = kruskal(low, lower, higher, high)
```

**Аргументы по умолчанию:**

- `nan_policy='propagate'` — обработка пропущенных значений

**Результат:**

Статистика H: 11.8121

p-value:  $0.0081 \leq 0.05$

**Вывод:** Отвергаем  $H_0$ , хотя бы одна медиана отличается от других

**Интерпретация:** Существует статистически значимая связь между уровнем домашнего насилия и рождаемостью в регионах. Регионы с разной интенсивностью домашнего насилия систематически различаются по показателям рождаемости.

## **8 Вывод**

В работе была проведена статистическая проверка шести критериев на данных по рождаемости 19 регионов Испании в 2023 году в дополнении с информацией о случаях домашнего насилия в каждом регионе за 2024 год.

Код реализации всех критериев на языке Python доступен по ссылке: